

赛题二：基于大模型推理的FlashAttention高性能硬件加速器IP设计

一、赛题背景

Transformer 架构已广泛应用于大模型（LLM/VLM）与多模态系统。在典型 Transformer 模型中，计算开销最为显著、同时对存储与带宽最为敏感的关键算子之一为 Scaled Dot-Product Attention（SDPA）：

$$O = \text{softmax}\left(\frac{QK^T}{\sqrt{d}} + M\right)V$$

其中 Q, K, V 为 Query/Key/Value, D 为每个 attention head 的维度, M 为 mask 例如 causal mask)。在朴素实现中，通常需要显式构造

$$QK^T$$

（大小约为 $S \times S$ ）及其 softmax 概率矩阵，从而引入如下问题：

- 带宽瓶颈：大量中间张量的读写使得性能受限于外存/显存带宽
- 存储压力：长序列下（约 $S \times S$ ）中间矩阵难以在片上存储
- 端侧落地困难：在功耗与 SRAM 受限的 SoC/加速器上难以高效实现

FlashAttention 系列工作提出了在线（online）softmax + 分块（tiling）+ 融合数据流的实现范式：在不显式存储（约 $S \times S$ ）注意力矩阵的前提下，完成与 SDPA 等价（或在可控近似误差范围内等价）的计算，从而显著降低带宽压力与中间存储开销。

本赛题要求参赛者使用 Cadence EDA 工具链，设计并实现一个可综合的 FlashAttention-style 注意力算子硬件 IP。参赛设计需在给定张量规模与接口规范下完成端到端注意力计算，并在正确性、性能（cycles/Fmax）、面积与带宽等维度进行综合评比。

二、赛题要求

参赛团队需要实现一个可综合 RTL IP，支持在指定输入规模下完成 SDPA/FlashAttention-style attention。

2.1 基本功能要求（必选）

(1) 算法定义（SDPA 计算目标）

设序列长度 S ，head 维度 d ，输出维度同 V 。对每个 query 位置 i ：

$$\text{score}_{ij} = \frac{Q_i \cdot K_j}{\sqrt{d}} + M_{ij}, P_{ij} = \frac{\exp(\text{score}_{ij})}{\sum_{t=0}^{S-1} \exp(\text{score}_{it})}, O_i = \sum_{j=0}^{S-1} P_{ij} V_j$$

(2) FlashAttention—style 计算约束

必须体现 FlashAttention—style 的关键思想，将据此验收：

- 禁止显式存储注意力矩阵
- 必须使用在线 (online) softmax
- 必须分块 (tiling) 处理 K/V

(3) 固定输入规模

为便于统一测试与比较，Baseline 固定如下规模（单 batch、单 head）：

- 序列长度：\$S = 256\$
- head 维度：\$d = 64\$
- Q/K/V/O 形状：\$[s, d]\$
- batch = 1, head = 1

(4) 数据格式（定点）

Baseline 统一采用定点格式（便于可综合、低面积／低功耗实现）：

- 输入 Q / K / V：Q8. 8（16-bit 有符号定点）
- 累加／中间：
- Dot-product 累加：至少 32-bit（建议 40-bit 以上以降低溢出风险）
- softmax 路径：允许使用更高位宽或分段缩放
- 输出 O：Q8. 8（16-bit 有符号定点）

(5) 接口要求

Baseline 统一采用 " 主机配置 + 加速器 DMA 搬运数据 " 的模式：

- AXI4-Lite（控制）：主机写寄存器（基地址／参数），并通过 CTRL.START 启动、读 STATUS 查询完成。
- AXI4 Master+DMA（数据）：加速器启动后用 DMA 从内存读入 Q, K, V，计算完成后把 O 写回内存。

(6) 寄存器

Baseline 固定 \$S = 256, d = 64\$。下表仅列出必需寄存器（其余可自行扩展）。

Offset	名称	访问	说明
--------	----	----	----

0x00	CTRL	R/W	bit0: START (写 1 启动) bit1: SOFT_RESET bit2: IRQ_EN
0x04	STATUS	R	bit0: BUSY bit1: DONE (写 1 清) bit2: ERROR
0x08	CFG	R/W	bit0: <u>CAUSAL_EN</u> (Baseline 必须支持) bit1: RESERVED
0x14	Q_BASE_L	R/W	Q 基地址 (低 32)
0x18	Q_BASE_H	R/W	Q 基地址 (高 32)
0x1C	K_BASE_L	R/W	K 基地址 (低 32)
0x20	K_BASE_H	R/W	K 基地址 (高 32)

0x24	V_BASE_L	R/W	V 基地址 (低 32)
0x28	V_BASE_H	R/W	V 基地址 (高 32)
0x2C	O_BASE_L	R/W	O 基地址 (低 32)
0x30	O_BASE_H	R/W	O 基地址 (高32)
0x34	STRIDE_BYTES	R/W	行 stride (bytes), 默认 $d \times 2$
0x38	NEG_LARGE	R/W	-inf 近似值 (Q8.8)
0x3C	SCALE	R/W	$1/\sqrt{d}$ 缩放常数
0x40	CYCLES	R	本次执行周 期数

(7) 存储与资源约束

为体现 FlashAttention-style 的 "低中间存储" 特性, Baseline 强约束:

- 禁止存储 score/p 全矩阵
- 片上中间 buffer 限额 (不含输入/输出缓存):

允许缓存一小块 K, V tile

允许每行维护 $m/l/acc$ (以及必要流水寄存器)

说明: 若参赛者选择把全量 K, V 缓存在片上 SRAM 以减少外存带宽, 需在报告中量化带宽收益与 SRAM 代价。

(8) 正确性验收

- 单向量对齐 (必测)

随机种子生成的 Q, K, V (Q8.8) 与 golden 输出。

- 误差门限

与 FP32 golden (同一公式、同一mask) 对比:

$$\text{mean_abs_error}(0) \leq 0.03$$

$$\text{max_abs_error}(0) \leq 0.10$$

若采用不同 exp/倒数近似, 需在文档中说明误差来源。

备注: Baseline 使用定点与近似运算, 不要求 bit-exact, 以误差门限作为验收标准。

(9) 测试验证

- 采用 SystemVerilog+UVM 或 Python+cocotb
- 必须包含:

AXI4-Lite 寄存器读写与启动/完成流程

随机 Q, K, V 的端到端验证

Causal mask corner case 验证 (如 $i = 0$ 行只能看 $j = 0$)

2.2 性能要求 (必选 Baseline)

(1) **主频目标:** 频率越高越好 (基于 Cadence Genus 物理综合报告; 鼓励进一步 P&R 收敛)

(2) **面积约束:** 等效逻辑门数 ≤ 200 万门 (含存储器折算, 统一用 Genus 报告的等效逻辑门数, 2-input NAND 等效口径)

(3) 延迟指标

单次 attention ($S = 256, d = 64$, causal) 执行周期数 $< 300k$ cycles

(4) 带宽目标

给出 RD_BYTES/WR_BYTES 统计与优化分析 (tile 缓存、复用等)

2.3 可选要求 (Bonus 加分项)

说明 (重要):

1. 所有 Bonus 必须在 Baseline 通过后开展。
2. 必须基于 Baseline 重新新建独立项目/独立版本 (例如新建目录或新工程), 单独开发、单独验证、单独提交。
3. 不得修改或影响 Baseline 版本的代码与评估结果 (Baseline 仍按原要求独立评测)。

4. 所有可选项可以在同一个 Bonus 项目中集中实现；该 Bonus 项目必须基于 Baseline 另行开发，并作为独立版本单独评估（重新仿真／重新综合／重新统计指标）。

Item	加分项	主要内容
1	BF16/FP16 版本	在相同尺寸下实现 BF16 或 FP16 attention (softmax／exp／倒数硬件化)，并给出误差与性能对比
2	多head支持	支持 head =4/8 ，接口增加 head 维度与地址／stride 管理
3	更长序列	支持 $S = 512$ （或可配置 S ），并保持不存储（约 $S \times S$ ）中间矩阵
4	Padding mask	支持输入有效长度 $L \leq S$ 的 padding mask（对无效 token 置 $-\text{inf}$ ）
5	其他定点格式	在Baseline的Q8.8之外，额外支持等价定点格式（如 Q6.10/Q4.12），并给出误差与性能对比
6	Dropout（训练模式）	在 softmax 后加入 dropout（需明确随机数产生方式与可复现种子）
7	更低精度（INT8/FP8 思路）	参考 FlashAttention-3 的低精度策略，实现块量化/分块缩放并给出误差收益
8	AXI4-Stream数据接口	在 Baseline（AXI4 Master+DMA）之外，额外提供 AXI4-Stream输入/输出接口，便于与其他 IP 级联
9	DMA／任务队列	支持多次 attention 连续执行（队列/链式配置），减少主机交互

三、工具支持：

Cadence 为本次比赛提供专属云服务器，服务器已预装赛事所需的 Cadence EDA 工具及对应工艺库。本次服务器资源充足，可保障每位参赛选手一人一个独立账号。

如需申请使用云服务器，请下载附件表格填写完整后提交，表格下载链接：

<https://cpipc.acge.org.cn/sysFile/downFile.do?fileId=40168f675ca64849be72024c9fb94256>

四、提交要求:

参赛队伍需提交主要材料：

代码与设计文件

(1) 完整的RTL代码 (Verilog/SystemVerilog)

- PQC加速器源代码 (ML-DSA + ML-KEM)
- Cadence工具脚本和约束文件 (SDC格式)

(2) 验证代码

- UVM/cocotb验证环境
- 测试用例和测试向量
- 仿真脚本

(3) Cadence工具生成的报告

- 仿真报告和波形文件
- 物理综合报告 (面积、时序、功耗)

报名后会提供提交内容参考模板